

朱俊苗

手机: 16686585985 邮箱: zjm0259@gmail.com

城市: 宁波 当前工作: 金唐软件 AI 开发工程师

项目方向: AI 工程化 / AI 后端开发



教育背景

哈尔滨工业大学 / 数学（计算数学方向）/ 理学学士

2020 年 - 2024 年

获数学建模竞赛省级奖项, 国家励志奖学金, 校优秀毕业论文

宁波大学 / 计算机科学与技术（医学人工智能方向）/ 工科专硕

2026 年 - 至今

统招非全日制硕士, 研究方向: 病理检测、生物医学工程、智能体系统。

核心亮点

- AI 应用全栈:** 熟悉 Java 与 Python 应用软件设计, 兼具前端能力, 具备从需求拆解到生产交付的端到端独立交付能力。
- 推理基础设施自建:** 主导 CosyVoice 推理框架异步化重构与服务化封装, 独立搭建 MaaS 平台网关鉴权与日志链路 (APISIX + RocketMQ), 统一接入 vLLM / MindIE 等多推理后端, 实现 LLM / TTS / ASR / Embedding 多模型标准化接入与统一调度。
- 多场景 AI 工程化落地:** 在智能问诊、模型服务、科研分析三类场景独立交付, 涵盖大模型接入、Agent 编排、RAG 增强检索等核心能力栈。

工作经历

金唐软件 / AI 开发工程师 (AI 应用组核心成员)

2024 年 - 至今

- 主要参与医疗大模型平台、智能问诊、临床决策支持、科研平台等医疗 AI 工程化项目。
- 工作内容覆盖大模型服务接入、AI 工作流编排、医疗业务系统集成、后端服务开发与部署运维。

代表项目

宁波市中医院智能问诊全流程

原有问诊流程中患者信息采集、语音交互、设备数据和 HIS 系统相互割裂, 数据无法结构化沉淀。我主导把离散环节统一进会话式 AI 工作流, 基于 LangGraph 设计患者状态管理、症状追问和节点跳转引擎, 通过状态图驱动问诊流程跳转, 将患者信息采集、症状追问、设备数据同步和 HIS 回写串成完整闭环。

前端通过 WebSocket 实现实时语音流推送, 后端基于 FastAPI 构建异步服务。TTS 接入 CosyVoice 流式推理并做分段合成, ASR 接入 SenseVoice 实时识别, 整体语音链路实现全双工流式交互。独立完成 CosyVoice 推理接口从同步到异步的全面改造, 重构其内部推理调度逻辑并封装为稳定服务接口。同时打通 MinIO 对象存储和多系统数据互通, 实现问诊数据从采集、结构化到回写 HIS 的完整闭环。

最终语音首包延迟从 2 s + 降至 200 ms 内, 问诊数据可结构化沉淀并回写 HIS, 已在宁波市中医院完成现场验证部署。

宁波市医疗 MaaS 平台

院内多业务系统直连大模型, 调用分散、私有化部署难管控、日志和权限不统一、缺乏标准化接入和运维管控能力。我参与建设统一的大模型能力出口和运维管控平台, 结合 APISIX 网关、RocketMQ 异步解耦和多模型推理服务形成标准化链路。

独立完成 APISIX 网关鉴权插件和 RocketMQ 异步日志链路建设, 在网关层实现 Token 鉴权、流量控制和调用日志采集, 解决多系统直连模型带来的权限和日志问题。推理层支持 vLLM、MindIE 等多后端统一接入, 管控层提供模型注册、版本管理和自动化发布流程。参与多模型推理服务的统一接入和定制开发, 支持 LLM、TTS、ASR、Embedding 等多类模型通过同一平台标准化接入和调度。

最终实现多模型统一管理和调用日志可追踪分析, 减少多系统直连带来的维护复杂度, 支撑宁波大市多家医院、院内 5+ 个业务系统的模型调用。

医疗科研平台

院内科研人员在文献阅读和科研创新方面缺乏智能化工具支持。我负责文献翻译和科研创新点挖掘两个核心模块的工程落地。

文献翻译模块：PDF 版面解析引入 Docling，底层使用 docling-layout 视觉模型将 PDF 逐页渲染为图像，通过布局识别模型输出段落、表格、图片等结构化分块，彻底替换了之前基于 PyMuPDF + bbox 几何算法的手动分块合并方案。翻译链路设计为异步并发流水线，每个分段独立提交 LLM（Qwen3-30B-A3B）翻译并追踪输入输出，前端支持并发块级渲染和翻译状态持久化复用（Java 负责任务调度与状态持久化，Python 负责 Docling 解析与 LLM 调用）。将同步 LLM 调用迁入线程池，修复了阻塞 asyncio 事件循环的性能瓶颈。

科研创新点挖掘模块：基于 Harness Engineering 思想设计多智能体架构——报告中的每个分析模块对应独立智能体，各自维护隔离的上下文和检索策略，支持无依赖模块并发生成。检索底座选用 LightRAG，除 chunk 向量外还抽取实体和关系构建轻量知识图谱，检索时组合图谱召回与向量召回，具备更强的跨文档关联推理能力。上层智能体通过检索接口按需获取上下文，无需在海量原文中盲目搜索。

文献翻译实现PDF 版面级保真翻译，支持并发多块同步渲染，全过程可追踪；创新点挖掘形成可复用的自动化分析框架，支持多模式多维度科研创新分析。

技术栈

- 编程语言：Python、Java、SQL
- 后端框架：FastAPI、Flask、SQLAlchemy、SQLModel、RESTful API、WebSocket、微服务架构
- AI 框架与引擎：PyTorch、LangChain、LangGraph、Hugging Face Transformers、LightRAG、Docling
- 大模型推理与部署：vLLM、MindIE、GGUF 量化、CosyVoice 流式推理
- 数据与存储：MySQL、PostgreSQL (PgVector)、Redis、MinIO、RocketMQ
- 云原生与 DevOps：Docker、Linux、Git、APISIX、Nginx
- AI 辅助工程：Claude Code、Codex、Qoder
- 工程方法：Prompt Engineering、Context Engineering、Harness Engineering

自我定位

AI 工程原住民——从 Prompt Engineering 到 Context Engineering 再到 Harness Engineering，每一步都走在技术演进的前沿，不少概念在被广泛讨论之前就已落地实践。日常以 AI 编程工具为工程基础设施，坚持用工程素养驾驭工具，而不是被工具驱动。